Módulo 3: Algoritmo de Grover, Hardware Real y Supercómputo Cuántico

(Prof. Pablo Benítez Llambay)

El Módulo 3 conecta la teoría algorítmica cuántica con los desafíos de la ingeniería física: transitar desde las simulaciones ideales en computadores clásicos hacia la ejecución en procesadores superconductores ruidosos de IBM Quantum y la aceleración de simulaciones de gran escala mediante GPUs.

Bloque 1: Conexión con IBM Quantum, Primitivas y Gestión de Cuota

Del simulador al chip cuántico superconductor

- **Entorno criogénico:** Los procesadores de IBM Quantum operan dentro de refrigeradores de dilución a temperaturas de **15 milikelvin** para mantener la superconductividad de los transmon qubits. Las instrucciones lógicas se envían vía web y controladores clásicos las traducen en pulsos electromagnéticos de microondas.
- **Autenticación y servicio:** La conexión se establece con la librería `qiskit_ibm_runtime` a través de `QiskitRuntimeService`. Se recomienda utilizar `save_account()` para guardar el API token localmente en `~/.qiskit/qiskit-ibm.json` en lugar de incluir credenciales dentro de los notebooks.
- **Primitiva `SamplerV2`:** Diseñada para algoritmos de búsqueda y muestreo probabilístico. Ejecuta el circuito un número fijo de disparos (*shots*) y retorna conteos de cadenas binarias colapsadas. Con la sintaxis moderna `qc.measure_all()`, Qiskit añade automáticamente los bits clásicos en el registro `'meas'`.
- **Síntesis del estado GHZ (3 qubits):** Extensión del estado entrelazado de Bell hacia 3 qubits correlacionados: $$|\text{GHZ}\rangle = \frac{|000\rangle + |111\rangle}{\sqrt{2}}$$ Se construye mediante una cascada de entrelazamiento: Hadamard en q_0 (H_0), seguida de $\text{CNOT}_{0 \to 1}$ y $\text{CNOT}_{1 \to 2}$. En un simulador ideal (`StatevectorSampler`), solo colapsa en `'000'` y `'111'`.

Física del tiempo cuántico y FinOps (Gestión de Cuota)

- **Tiempo en cola vs. Tiempo neto de QPU:** IBM ofrece una cuota mensual gratuita de **10 minutos** de procesador. El tiempo en cola (espera en servidores clásicos) es gratuito. Solo se descuenta el tiempo físico en que los pulsos de microondas excitan los qubits en el criostato.

- **Escalas temporales de las compuertas:**
  - Compuertas de 1 qubit (X, H): $\mathcal{O}(10^{-9}\text{ s})$.
  - Compuertas de 2 qubits (CZ, CNOT, ECR): $\mathcal{O}(10^{-8}\text{ s})$.
  - Pulsos de medición/lectura: $\mathcal{O}(10^{-6}\text{ s})$.
  - Tiempo de relajación térmica entre disparos: $\sim 100\ \mu\text{s}$.
  - Una corrida de **1024 disparos** consume apenas entre **1 y 3 segundos netos de procesador**, lo que permite realizar entre $\mathcal{O}(10^2)$ experimentos al mes si se valida previamente en local.
- **Presupuesto de disparos y error estadístico:** La desviación estándar del estimador de probabilidad $\hat{p}$ sigue la ley de los grandes números: $$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{N_{\text{disparos}}}} \sim \mathcal{O}\left(\frac{1}{\sqrt{N_{\text{disparos}}}}\right)$$ Para el peor escenario ($p = 0.5$) y $N = 1024$, el error estadístico con un 95% de confianza ($\pm 2\sigma$) es de solo $\pm 3.1\%$.
- **Despacho asíncrono temprano:** Selección del procesador menos ocupado con `service.least_busy()`, transpilación con `optimization_level=3` (para mapear a los qubits físicos con menores tasas de error del chip) y registro del `job_id` para continuar la sesión teórica sin bloquear el computador.

Bloque 2: Búsqueda Cuántica y Algoritmo de Grover

El problema de la aguja en el pajar y la aceleración cuántica

- **Búsqueda desestructurada:** Localizar un elemento objetivo ω en un espacio no ordenado de $N = 2^n$ estados mediante consultas a un oráculo booleano $f(x)$ que vale 1 si $x = \omega$ y 0 si $x \neq \omega$.
- **Límite clásico vs. cuántico:**
  - Clásicamente requiere evaluar en promedio $N/2$ candidatos, con complejidad lineal $\mathcal{O}(N)$.
  - Grover logra una **aceleración cuadrática** resolviendo la búsqueda en $T_{\text{cuántico}} \sim \mathcal{O}(\sqrt{N})$ pasos ($T_{\text{clásico}} \sim T_{\text{cuántico}}^2$).
- **El mito de la superposición:** Preparar una superposición uniforme $|s\rangle = \frac{1}{\sqrt{N}}\sum |x\rangle$ y medir entrega una probabilidad de acierto de apenas $1/N$, idéntica a adivinar al azar. La ventaja radica en la **interferencia cuántica destructiva** (cancelación de estados incorrectos) y **constructiva** (amplificación de la solución).

Intuición geométrica en un plano 2D

Toda la dinámica de Grover ocurre en un subespacio bidimensional ortogonal generado por:

1. El vector solución $|\omega\rangle$ (eje vertical).

2. El vector de estados incorrectos $|s'\rangle = \frac{1}{\sqrt{N-1}}\sum_{x \neq \omega}|x\rangle$ (eje horizontal).

- Se demuestra algebraicamente que $\langle \omega | s'\rangle = 0$.
- El estado inicial se expresa trigonométricamente como: $$|s\rangle = \cos(\theta)|s'\rangle + \sin(\theta)|\omega\rangle, \quad \text{con } \sin(\theta) = \frac{1}{\sqrt{N}} \implies \theta \approx \frac{1}{\sqrt{N}}$$ Para N grande, $|s\rangle$ inicia casi pegado al eje horizontal.

Operadores del algoritmo

1. **Oráculo de Fase (U_ω):** Invierte el signo del estado objetivo ($U_\omega = I - 2|\omega\rangle\langle\omega|$). Geométricamente representa una **reflexión respecto al eje horizontal $|s'\rangle$**.
   - *Implementación circuital:* Compuerta multi-controlada X (`mcx`) con compuertas Hadamard en el qubit objetivo ($HXH = Z$), y compuertas X envolventes en los qubits cuyo bit sea `'0'` en la convención *Little-Endian*.
2. **Operador de Difusión (D):** Realiza una inversión respecto a la media de todas las amplitudes: $$D = 2|s\rangle\langle s| - I = H^{\otimes n}\left(2|0\rangle^{\otimes n}\langle 0|^{\otimes n} - I\right) H^{\otimes n}$$ Geométricamente es una **reflexión respecto al vector $|s\rangle$**.
3. **Rotación combinada e iteraciones óptimas:** La combinación de ambas reflexiones produce una rotación neta hacia $|\omega\rangle$ de ángulo 2θ en cada iteración. Para alcanzar el estado solución se requieren: $$k \approx \text{round}\left(\frac{\pi}{4}\sqrt{N}\right)\text{ pasos}$$ Para 3 qubits ($N = 8$), $k = 2$ iteraciones concentran la probabilidad teórica en $|110\rangle$ en un **$\approx 95\%$**. Iterar más veces provocaría *sobre-rotación*, reduciendo la probabilidad.

Bloque 3: Topología de Hardware, Ruido Físico y Simulación GPU

Restricciones físicas y transpilación

- **Conectividad del chip:** Los procesadores superconductores no poseen conectividad *all-to-all*; disponen de topologías fijas (mallas pesadas o líneas). Para interactuar qubits no adyacentes, el compilador debe insertar compuertas **SWAP** (equivalentes a 3 CNOTs cada una).
- **Niveles de optimización:**
  - `optimization_level=0` : Mapeo directo y expansión de compuertas sin simplificación.
  - `optimization_level=3` : Reordena conmutaciones, cancela compuertas redundantes y ubica los qubits virtuales en el subgrafo físico de menor ruido y mayor coherencia (T_1, T_2).

Modelado de ruido físico

- Las compuertas de 2 qubits son las principales fuentes de error (tasas de error de despolarización de 1% a 3%, frente a $<0.1\%$ en compuertas de 1 qubit).
- Al inyectar un modelo de ruido de despolarización de 2.0% en las compuertas CX, la fidelidad de Grover decae significativamente (la probabilidad de éxito en simulación cae del $\sim 95\%$ teórico a valores en torno al $60\%-70\%$), elevando el piso de ruido de los estados espurios.

El muro de memoria clásica y aceleración GPU

- **Crecimiento exponencial:** Almacenar el vector de estado cuántico en una computadora clásica requiere $2^n \times 16\text{ bytes}$.
  - 10 qubits $\to 16\text{ KB}$
  - 20 qubits $\to 16\text{ MB}$
  - 30 qubits $\to 16\text{ GB}$
  - 40 qubits $\to 16\text{ TB}$
- A partir de 24-26 qubits, un procesador clásico monohilo agota la memoria RAM y sufre severos cuellos de botella por ancho de banda de memoria.
- **Aceleración con cuQuantum / NVIDIA A100:** Utilizando `AerSimulator(method="statevector", device="GPU")`, el paralelismo masivo de hilos de la GPU y el ancho de banda de la memoria HBM aceleran la aplicación de operadores unitarios, logrando factores de aceleración (*speedup*) medibles de hasta varios órdenes de magnitud frente a un núcleo de CPU.

Bloque 4: Mitigación de Errores y Hardware Real

Análisis de resultados en QPUs físicas

- Al recuperar el trabajo de Grover ejecutado en un procesador real (ej. *IBM Heron* / *ibm_torino* con 4096 disparos), la distribución se encuentra degradada por decoherencia y errores de lectura (SPAM):
  - Probabilidad ideal: $\sim 95.5\%$
  - Probabilidad cruda en chip real: $\sim 48.4\%$
  - Piso de ruido medio en estados espurios: $\sim 7.4\%$
  - **Contraste señal/ruido (SNR):** A pesar del ruido, la señal domina por un factor de **$\approx 6.6\times$** sobre el fondo aleatorio, confirmando que la interferencia constructiva de Grover sobrevive en hardware NISQ.

Mitigación matricial de lectura (*Readout Mitigation*)

- **Modelado de la matriz de asignación (A):** Sean ϵ_0 y ϵ_1 las tasas de error de falso positivo y falso negativo al leer un qubit: $$A_{1q} =

\begin{pmatrix} 1 - \epsilon_0 & \epsilon_1 \\ \epsilon_0 & 1 - \epsilon_1 \end{pmatrix}$$

- **Extensión a n qubits:** Asumiendo errores de medición independientes, la matriz de confusión del registro completo se obtiene por productos de Kronecker: $$A_{3q} = A_{1q} \otimes A_{1q} \otimes A_{1q}$$
- **Inversión lineal:** Se corrige el vector de probabilidades observado aplicando la inversa matricial: $$P_{\text{mitigado}} = A_{3q}^{-1} P_{\text{real}}$$ Tras normalizar y recortar componentes negativas espurias, la probabilidad del estado solución $|110\rangle$ pasa de 48.4% a **54.3%** ($+5.9$ puntos porcentuales de visibilidad), demostrando cómo el post-procesamiento clásico de datos permite rescatar fidelidad sin alterar el procesador cuántico.